

luoyue's Math Notes

luoyue

[GitHub:luoyueyugaung](#)

第一部分

微积分

1 函数与数列的极限

1.1 极限

定义 1.1.1: 数列极限的定义

$\lim_{n \rightarrow \infty} x_n = A \Leftrightarrow \forall \varepsilon > 0, \exists \text{ 正整数 } N, \text{ 使得当 } n > N \text{ 时 } |x_n - A| < \varepsilon.$
若数列 $\{x_n\}$ 存在极限, 又称数列 x_n 收敛, 否则数列 $\{x_n\}$ 发散。

定义 1.1.2: 函数极限的定义

$\lim_{x \rightarrow \infty} f(x) = A \Leftrightarrow \forall \varepsilon > 0, \exists \text{ 正数 } X \text{ 使得当 } |x| > X \text{ 时 } |f(x) - A| < \varepsilon.$
单侧极限:

$\lim_{x \rightarrow +\infty} f(x) = A \Leftrightarrow \forall \varepsilon > 0, \exists \text{ 正数 } X \text{ 使得当 } x > X \text{ 时 } |f(x) - A| < \varepsilon.$

$\lim_{x \rightarrow -\infty} f(x) = A \Leftrightarrow \forall \varepsilon > 0, \exists \text{ 正数 } X \text{ 使得当 } x < -X \text{ 时 } |f(x) - A| < \varepsilon.$

定义 1.1.3: 函数极限的定义

$\lim_{x \rightarrow x_0} f(x) = A \Leftrightarrow \forall \varepsilon > 0, \exists \text{ 正数 } \delta \text{ 使得当 } 0 < |x - x_0| < \delta \text{ 时, } |f(x) - A| < \varepsilon.$ 类似可定义左极限与右极限。

结论 1.1.1: 数列极限的基本性质

1. 数列极限的不等式

设 $\lim_{n \rightarrow \infty} x_n = A, \lim_{n \rightarrow \infty} y_n = B$

若 $a > b, \exists N, \text{ 当 } n > N \text{ 时有 } x_n > y_n;$

若 $n > N \text{ 时有 } x_n < y_n, \text{ 则 } a \geq b.$

2. 收敛数列的有界性

设 $\{x_n\}$ 是收敛数列, $\lim_{n \rightarrow \infty} x_n = A, \text{ 则 } \{x_n\} \text{ 有界}.$

结论 I.1.2: 函数极限的基本性质

1. 函数极限的不等式

设 $\lim_{x \rightarrow x_0} f(x) = A$, $\lim_{x \rightarrow x_0} g(x) = B$

若 $A > B$, $\exists \delta > 0$, 使得当 $0 < |x - x_0| < \delta$ 时有 $f(x) > g(x)$,

若 $\exists \delta > 0$, 使得当 $0 < |x - x_0| < \delta$ 时有 $f(x) \geq g(x)$, 则 $A \geq B$.

若 $f(x) > g(x)$, 仍然为 $A \geq B$

函数极限的保号性

设 $\lim_{x \rightarrow x_0} f(x) = A$,

若 $A > 0$, 则 $\exists \delta > 0$, 使得当 $0 < |x - x_0| < \delta$ 时有 $f(x) > 0$.

若 $\exists \delta > 0$, 使得当 $0 < |x - x_0| < \delta$ 时有 $f(x) \geq 0$, 则 $A \geq 0$.

2. 存在极限的函数的局部有界性

设 $\lim_{x \rightarrow x_0} f(x) = A$, 则 $f(x)$ 在 x_0 的某空心邻域 $\bigcup_0(x_0, \delta) = \{x | 0 < |x - x_0| < \delta\}$ 内有界, 即 $\exists \delta > 0$ 与 $M > 0$, 使得当 $0 < |x - x_0| < \delta$ 时有 $|f(x)| \leq M$.

公式 .1: 重要的极限

$$\begin{aligned}\lim_{x \rightarrow 0} \frac{\sin x}{x} &= 1, \\ \lim_{x \rightarrow 0} (1+x)^{\frac{1}{x}} &= e \text{ 或} \\ \lim_{x \rightarrow \infty} \left(1 + \frac{1}{x}\right)^x &= e, \\ \lim_{x \rightarrow 0} \frac{\ln(1+x)}{x} &= 1\end{aligned}$$

结论 I.1.3: 夹逼定理

1. 数列 $\exists N$, 当 $n > N$ 时有 $y_n \leq x_n \leq z_n$, $\lim_{n \rightarrow \infty} y_n = a$, $\lim_{n \rightarrow \infty} z_n = a$,
则 $\lim_{n \rightarrow \infty} x_n = a$ 。

2. 函数 $\exists \delta > 0$, 当 $0 < |x - x_0| < \delta$ 时有 $h(x) \leq f(x) \leq g(x)$, 又
 $\lim_{x \rightarrow x_0} h(x) = A$, $\lim_{x \rightarrow x_0} g(x) = A$, 则 $\lim_{x \rightarrow x_0} f(x) = A$ 。

结论 I.1.4: 单调有界数列必收敛定理

若数列 $\{x_n\}$ 单调上升有上界, 即 $x_{n+1} \geq x_n$ 且 $\exists M$, 当 $n > N$ 时有 $x_n \leq M$, 即存在一个数 a , 使得 $\lim_{n \rightarrow \infty} x_n = a$, 且 $x_n \leq a$.

若数列 $\{x_n\}$ 单调下降有下界, 即 $x_{n+1} \leq x_n$ 且 $\exists M$, 当 $n > N$ 时有 $x_n \geq M$, 即存在一个数 a , 使得 $\lim_{n \rightarrow \infty} x_n = a$, 且 $x_n \geq a$.

结论 I.1.5: 极限存在的充要条件

1. 函数极限

$$\lim_{x \rightarrow x_0} f(x) = A \Leftrightarrow \lim_{x \rightarrow x_0^-} f(x) = A = \lim_{x \rightarrow x_0^+} f(x) = A$$

即左右极限都存在且相等。

2. 数列极限

$$\lim_{n \rightarrow \infty} x_n = A \Leftrightarrow \lim_{n \rightarrow \infty} x_{2n} = A = \lim_{n \rightarrow \infty} x_{2n-1} = A = \dots$$

即数列的任意子列极限都等于原数列的极限。

公式 .2: 证明极限不存在的常用方法

1. $x \rightarrow x_0$ 时, 左右极限不相等则极限不存在

$x \rightarrow \infty$ 时, $-\infty$ 与 $+\infty$ 极限不相等, 则极限不存在

2. $\exists x_n \rightarrow x_0$, 但 $\lim_{n \rightarrow \infty} x_n \neq A$, 则极限不存在。

$x_n \rightarrow x_0, y_n \rightarrow y_0$, 但 $\lim_{n \rightarrow \infty} x_n \neq \lim_{n \rightarrow \infty} y_n$, 则 $\lim_{x \rightarrow x_0} f(x)$ 不存在

3. 利用结论, $\lim_{x \rightarrow x_0} f(x) = A, \lim_{x \rightarrow x_0} g(x)$ 不存在。则 $\lim_{x \rightarrow x_0} [f(x) + g(x)]$ 不存在。若 A 不为零, 则 $\lim_{x \rightarrow x_0} [f(x) \cdot g(x)]$ 不存在。

1.2 求极限的方法

结论 I.1.6: 极限的四则运算法则

$$1. \lim_{x \rightarrow x_0} [f(x) \pm g(x)] = \lim_{x \rightarrow x_0} f(x) \pm \lim_{x \rightarrow x_0} g(x)$$

$$2. \lim_{x \rightarrow x_0} [f(x) \cdot g(x)] = \lim_{x \rightarrow x_0} f(x) \cdot \lim_{x \rightarrow x_0} g(x)$$

$$3. \lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = \frac{\lim_{x \rightarrow x_0} f(x)}{\lim_{x \rightarrow x_0} g(x)}$$

注 若运算中 $[f(x) \text{ 或 } g(x)]$ 不存在或为 ∞ , 则 $\lim_{x \rightarrow x_0} [f(x) \pm g(x)]$ 不存在或为 ∞ 。若存在的极限不为 0, 则 $\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)}$ 与 $\lim_{x \rightarrow x_0} f(x) \cdot g(x)$ 均不存在或为 ∞ 。

若运算中 $[f(x) \text{ 且 } g(x)]$ 均不存在或为 ∞ , 则 $f(x) \pm g(x)$, $f(x) \cdot g(x)$, $\frac{f(x)}{g(x)}$ 的极限需作具体分析

结论 I.1.7: 幂指数函数的极限运算法则

$$\lim_{x \rightarrow x_0} [f(x)] = A, \lim_{x \rightarrow x_0} [g(x)] = B, \lim_{x \rightarrow x_0} [f(x)]^{[g(x)]} = A^B$$

1. $A > 0$ 且 $A \neq 1$ 或 ∞ , $B = +\infty$

$$\lim_{x \rightarrow x_0} [f(x)]^{[g(x)]} = \begin{cases} 0, & 0 < A < 1 \\ +\infty, & A > 1 \end{cases}$$

2. $A > 0$, $f(x) > 0$, $0 < |x - a| < \delta$, $B \neq 0$

$$\lim_{x \rightarrow x_0} [f(x)]^{[g(x)]} = \begin{cases} 0, & B > 0 \\ +\infty, & B < 0 \end{cases}$$

3. $A = +\infty$, $B \neq 0$

$$\lim_{x \rightarrow x_0} [f(x)]^{[g(x)]} = \begin{cases} +\infty, & B > 0 \\ 0, & B < 0 \end{cases}$$

结论 I.1.8: 运算法则不适用的未定式

$$\frac{0}{0}, \frac{\infty}{\infty}, 0 \cdot \infty, \infty - \infty, 0^0, \infty^0, 1^\infty$$

结论 I.1.9: 利用函数的连续性求极限

$\lim_{x \rightarrow x_0} f(x) = A$, 若 $f(x)$ 在 x_0 处连续, 则 $f(x)$ 在 x_0 处的极限为 $A = f(x_0)$ 。

结论 I.1.10: 利用变量替换法求极限

1. $\lim_{x \rightarrow +\infty} \varphi(x) = +\infty$ 且 $\lim_{u \rightarrow \infty} f(u) = A$,
则 $\lim_{x \rightarrow +\infty} f[\varphi(x)] \stackrel{x=\varphi(x)}{=} \lim_{u \rightarrow \infty} f(u) = A$.
2. $\lim_{x \rightarrow x_0} \varphi(x) = u_0$ 且 $f(u)$ 在 u_0 处连续,
则 $\lim_{x \rightarrow x_0} f[\varphi(x)] \stackrel{u=\varphi(x)}{=} \lim_{x \rightarrow x_0, u \rightarrow u_0} f(u) = A$.

结论 I.1.11: 利用等价无穷小代换求极限

若 $x \rightarrow a$ 时有, 无穷小 $\alpha(x) \sim \alpha^*(x), \beta(x) \sim \beta^*(x)$,

$$\text{则 } \lim_{x \rightarrow a} \frac{\alpha(x)u(x)}{\beta(x)v(x)} = \lim_{x \rightarrow a} \frac{\alpha^*(x)u(x)}{\beta^*(x)v(x)} = \frac{\lim_{x \rightarrow a} \alpha^*(x) \lim_{x \rightarrow a} u(x)}{\lim_{x \rightarrow a} \beta^*(x) \lim_{x \rightarrow a} v(x)} = \frac{\alpha^*(a)u(a)}{\beta^*(a)v(a)}$$

结论 I.1.12: 利用洛必达法则求极限

适用于 $\frac{0}{0}, \frac{\infty}{\infty}, \lim_{x \rightarrow a} \frac{f(x)}{g(x)} = \lim_{x \rightarrow a} \frac{f'(x)}{g'(x)} = A$

结论 I.1.13: 求数列极限的方法

1. 利用函数极限求数列极限, 将所求数列 $\{y_n\}$ 看作函数 $f(x)$ 在数列 $\{x_n\}$ 上的取值, 则 $\lim_{n \rightarrow \infty} y_n = \lim_{n \rightarrow \infty} f(x_n) = \lim_{x \rightarrow +\infty} f(x) = A$
2. 使用放缩法, 处理余项
3. 利用递归方法, 若所求数列 $\{y_n\}$ 满足 $y_{n+1} = f(y_n)$, 则设 $\lim_{n \rightarrow \infty} y_n = A$, 求 $A = f(A)$ 即可

结论 I.1.14: 其他求极限的方法

1. 利用导数定义求极限
2. 利用泰勒公式求极限

3. 利用定积分求极限

1.3 无穷小

定义 1.1.4: 无穷小的定义

1. 数列若 $\lim_{n \rightarrow \infty} x_n = 0$, 则称数列 x_n 为无穷小, 记为 $x_n = o(1)(n \rightarrow \infty)$
2. 函数若 $\lim_{x \rightarrow x_0} f(x) = 0$, 则称函数 $f(x)$ 在 x_0 处为无穷小, 记为 $f(x) = o(1)(x \rightarrow x_0)$

定义 1.1.5: 无穷大的定义

1. 数列
若 $\forall M > 0, \exists N, \forall n > N, |x_n| > M$, 则称数列 x_n 为无穷大, 记为 $\lim_{x_n \rightarrow \infty} x_n = \infty$
2. 函数
若 $\forall M > 0, \exists X > 0, \forall |x| > X, |f(x)| > M$, 则称 $x \rightarrow \infty$ 时 $f(x)$ 为无穷大量, 记为 $\lim_{x \rightarrow \infty} f(x) = \infty$
若 $\forall M > 0, \exists \delta > 0, 0 < |x - x_0| < \delta$ 时有 $|f(x)| > M$, 则称 $x \rightarrow x_0$ 时 $f(x)$ 为无穷大量, 记为 $\lim_{x \rightarrow x_0} f(x) = \infty$

结论 1.1.15: 无穷小的关系

1. 与极限的关系
 $\lim_{x \rightarrow x_0} f(x) = A \Leftrightarrow f(x) = A + \alpha(x), \lim_{x \rightarrow x_0} \alpha(x) = 0$
2. 与无穷大的关系若 $f(x)$ 为无穷小, 若 $f(x) \neq 0$, 则 $\frac{1}{f(x)}$ 为无穷大, 反之亦成立。

结论 1.1.16: 无穷小的运算性质

1. 有限个无穷小的代数和仍为无穷小
2. 有限个无穷小的代数积仍为无穷小
3. 有界变量与无穷小的乘积仍为无穷小

定义 I.1.6: 无穷小阶的定义

若 $f(x) = o(1)(x \rightarrow x_0)$, 则称 $f(x)$ 为无穷小阶, 记为 $f(x) = o(1)(x \rightarrow x_0)$

公式 .3: 常见的等价无穷小

当 $x \rightarrow 0$ 时, 有

1. $\sin x \sim x$

2. $\tan x \sim x$

3. $\arcsin x \sim x$

4. $\arctan x \sim x$

5. $1 - \cos x \sim \frac{1}{2}x^2$

6. $e^x - 1 \sim x$

7. $\ln(1 + x) \sim x$

8. $a^x - 1 \sim x \ln a (a > 0, a \neq 1)$

9. $(1 + \beta x)^\alpha - 1 \sim \alpha \beta x$

10. $\log_a(1 + x) \sim \frac{1}{\ln a}x (a > 0, a \neq 1)$

11. $\sqrt[n]{1 + x} - 1 \sim \frac{1}{n}x$

结论 I.1.17: 等价无穷小的重要性质

结论 I.1.18: 确定无穷小阶的方法

2 一元函数微分学

2.1 一元函数的导数与微分

定义 1.2.1: 导数的定义

设函数 $f(x)$ 在 x_0 的某邻域有定义, 若极限

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$

存在, 则称 $f(x)$ 在 x_0 处可导, 并称此极限为 $f(x)$ 在 x_0 处的导数, 记为

$$f'(x_0) = y'(x_0) = \left. \frac{dy}{dx} \right|_{x=x_0} = \left. \frac{df(x)}{dx} \right|_{x=x_0} = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

即令 $x = x_0 + \Delta x$ 则定义式为

$$\lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

定义 1.2.2: 单侧导数的定义

左右导数为

$$f'_-(x_0) = \lim_{\Delta x \rightarrow 0^-} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0^-} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$
$$f'_+(x_0) = \lim_{\Delta x \rightarrow 0^+} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0^+} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$

结论 1.2.1: 导数的几何意义与力学意义

导数的几何意义为函数在 x_0 处的切线的斜率, 即函数在 x_0 处的变化率。

导数的力学意义为质点作直线运动, $x = x(t)$, $x'(t)$ 为 x 的速度, $x''(t)$ 为 x 的加速度。

结论 1.2.2: 单侧可导与双侧可导的关系

$f(x)$ 在 x_0 处可导 $\Leftrightarrow f(x)$ 在 x_0 处左右导数均存在且相等, 即

$$f'(x_0) = f'_-(x_0) = f'_+(x_0)$$

定义 1.2.3: 可微的定义

设函数 $f(x)$ 在 x_0 的邻域内有定义, 当自变量 $x = x_0$ 有增量 Δx 时, 若存在与 Δx 无关的常数 $A(x_0)$, 使得函数的增量 $\Delta y = f(x_0 + \Delta x) - f(x_0)$ 可表为

$$\Delta y = A(x_0)\Delta x + o(\Delta x) (\Delta x \rightarrow 0)$$

则称 $f(x)$ 在 x_0 处可微, 并称 $A(x_0)$ 为 $f(x)$ 在 x_0 处的微分, 记为

$$dy|_{x=x_0} = A(x_0)\Delta x \text{ 或 } df(x)|_{x=x_0} = A(x_0)\Delta x$$

其中 $o(\Delta x)$ 是该函数在 $x = x_0$ 处函数增量的线性主要部分 (简称线性主部)

定义 1.2.4: 微分的几何意义

$\Delta y = f(x_0 + \Delta x) - f(x_0) = A(x_0)\Delta x + o(\Delta x)$ 是曲线 $y = f(x)$ 在 x_0 相应于自变量增量 x 的纵坐标 $f(x_0)$ 的增量

结论 1.2.3: 可微、可导与连续的关系

$f(x)$ 在 x_0 处可导 $\Leftrightarrow f(x)$ 在点 x_0 处可微 $\Leftrightarrow$ 函数 $f(x)$ 在 x_0 处连续。

结论 1.2.4: 函数在区间上的可导性

$\forall x \in (a, b), f(x)$ 可导, 则称 $f(x)$ 在开区间 (a, b) 内可导,
若 $f(x)$ 在 (a, b) 内可导, 且 $f(x)$ 既在 $x = a$ 处右可导, 又在 $x = b$ 处左可导, 则称 $f(x)$ 在闭区间 $[a, b]$ 可导

定义 1.2.5: 导函数的定义

设函数 $f(x)$ 在区间 I 可导, 则 $\forall x \in I$ 都对应着 $f(x)$ 的一个确定的函数值 $f'(x)$, 这就构成了一个新的函数称此函数为 $f(x)$ 的导函数, 或 $f(x)$ 的一次导数。

定义 1.2.6: 二阶导数及高阶导数的定义

导函数 $f'(x)$ 的导数为二阶导数, 记为 $y'', f''(x), \frac{d^2y}{dx^2}, \frac{d}{dx}(\frac{dy}{dx})$, $y = f(x)$ 的 $n - 1$ 阶导函数 $f^{(n-1)}(x)$ 的导数称为 $y = f(x)$ 的 n 阶导数, 记作 $y^{(n)}, f^{(n)}(x), \frac{d^ny}{dx^n}$ 其表达式为

$$f''(x_0) = \lim_{\Delta x \rightarrow 0} \frac{f'(x_0 + \Delta x) - f'(x_0)}{\Delta x}$$
$$f^{(n)}(x_0) = \lim_{\Delta x \rightarrow 0} \frac{f^{(n-1)}(x_0 + \Delta x) - f^{(n-1)}(x_0)}{\Delta x}$$

结论 1.2.5: 奇偶函数与周期函数的导数性质

设函数 $f(x)$ 在 I 上可导, 则在 I 上

若 $f(x)$ 为奇函数 $\Rightarrow$ 则 $f'(x)$ 为偶函数;

若 $f(x)$ 为偶函数 $\Rightarrow$ 则 $f'(x)$ 为奇函数;

若 $f(x)$ 为周期函数, 以 T 为周期 $\Rightarrow$ 则 $f'(x)$ 为周期函数, 以 T 为周期

2.2 求导方法

3 微分中值定理与泰勒公式

4 一元函数积分学

第二部分

概率论

1 随机事件及其概率

1.1 随机事件

定义 II.1.1: 随机试验

随机试验满足一下三个条件：

1. 可以在相同的条件下重复进行；
2. 每次试验的结果不确定；
3. 所有可能的结果都明确可知且不止一个。

定义 II.1.2: 样本空间

样本空间是指随机试验所有可能结果的集合，通常用 Ω 表示。

定义 II.1.3: 随机事件

随机事件是样本空间的一个子集，通常用大写字母表示，如 A, B, C 等。事件可以是单个结果，也可以是多个结果的集合。

每次试验中必定发生的事件称为必然事件，记作 Ω ；不可能发生的事件称为不可能事件，记作 $\emptyset$ 。

1.2 事件的关系与运算

表 1: 事件的关系与运算

事件	记号	说明
并集	$A \cup B$	至少发生事件 A 或事件 B
交集	$A \cap B$	同时发生事件 A 和事件 B
差集	$A - B$	发生事件 A 但不发生事件 B
对立	A^c	事件 A 的补集, 即不发生事件 A
包含	$A \subseteq B$	事件 A 是事件 B 的子集, 即 A 的发生包含在 B 的发生中
相等	$A = B$	事件 A 和事件 B 完全相同, 即它们包含的结果完全一致
互斥	$A \cap B = \emptyset$	事件 A 和事件 B 不能同时发生, 即它们没有共同的结果
完备	$\bigcup_{i=1}^n A_i = \Omega$	事件 $A_1, A_2, \dots, A_n$ 的并集等于样本空间 Ω , 即这些事件的发生覆盖了所有可能的结果

1.3 事件的运算法则

公式 .4: 事件的运算法则

- 交换律: $A \cup B = B \cup A$, $A \cap B = B \cap A$
- 结合律: $A \cup (B \cup C) = (A \cup B) \cup C$, $A \cap (B \cap C) = (A \cap B) \cap C$
- 分配律: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$, $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- 德摩根定律: $(A \cup B)^c = A^c \cap B^c$, $(A \cap B)^c = A^c \cup B^c$
- 吸收律: 若 $A \subset B$, 则 $A \cup B = B$, $A \cap B = A$
- 对立律: $A \cup A^c = \Omega$, $A \cap A^c = \emptyset$
- 蕴涵律: $A \cap B = \emptyset \Rightarrow A \subset B^c$, $B \subset A^c$
- 差积律: $A - B = A \cap B^c = A - (A \cap B)$

1.4 概率的定义

定义 II.1.4: 概率的描述性定义

概率是指在大量重复的随机试验中，某事件发生的频率趋近于一个固定值，这个固定值即为该事件的概率。

定义 II.1.5: 概率的公理化定义

概率是一个函数 P ，定义在样本空间 Ω 的子集上，满足以下公理：

1. 非负性：对于任意事件 A ， $P(A) \geq 0$ 。
2. 归一性： $P(\Omega) = 1$ 。
3. 可列可加性：对于任意互不相交的事件序列 $\{A_i\}$ ，有 $P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ 。

定义 II.1.6: 概率的统计定义

概率是指在大量重复的随机试验中，某事件发生的相对频率趋近于一个固定值，这个固定值即为该事件的概率。

定义 II.1.7: 概率的几何定义

在几何空间中，概率可以通过测度来定义。对于一个事件 A ，其概率可以表示为事件 A 在样本空间 Ω 中的测度与样本空间 Ω 的测度之比，即 $P(A) = \frac{m(A)}{m(\Omega)}$ ，其中 m 表示测度。

定义 II.1.8: 古典概型

古典概型是指在有限样本空间中，每个基本事件发生的概率相等的情况。设样本空间 Ω 包含 n 个基本事件，事件 A 包含 m 个基本事件，则事件 A 的概率为：

$$P(A) = \frac{m}{n}$$

公式 .5: 古典概型的计算方法

1. 随机分配问题

一共有 N 种物品，每种物品有 n 个可选项。每个物品可以独立选择一个可选项，因此总共有 N^n 种选择方式。从 n 个物品中选择 k 个物品的方式有 C_n^k 种，选择的 k 个物品可以任意排列，因此有 $k!$ 种排列方式。剩余的 $n - k$ 个物品可以从 $N - k$ 个剩余物品中选择，因此有 $(N - k)^{n-k}$ 种选择方式。因此得到公式：

$$P(C) = \frac{C_n^k k! (N - k)^{n-k}}{N^n} = \frac{n! (N - k)^{n-k}}{(n - k)! N^n}$$

2. 简单随机抽样问题

Ω 包含 N 个元素，如果各元素被选中的概率相等，则 Ω 的抽样被称作简单随机抽样。

表 1: 简单随机抽样的计算方法

抽样方式	公式	说明
有放回抽样	$P_N^n = N^n$	每次抽样后元素仍然可选，选择 n 个元素
无放回抽样	$P_N^n = \frac{N!}{(N-n)!}$	每次抽样后元素不再可选，选择 n 个元素
无放回抽样（组合）	$C_N^n = \frac{N!}{n!(N-n)!}$	每次抽样后元素不再可选，选择 n 个元素且不考虑顺序

3. 其他方法

如果只是一些简单的抽样的话不需要考虑这么复杂的公式

(a) 直接列举法：对于小规模样本空间，可以直接列举所有可能的事件。

(b) 排列组合法：对于有序或无序的事件，可以使用排列组合的方法来计算概率。

(c) 容斥原理：对于多个事件的并集，可以使用容斥原理来计算概率。

4. **例** 将 n 个不同的物品放入 m 个不同的盒子中，每个盒子可以放任意数量的物品

(a) 有放回抽样：每个物品可以放入任意盒子，因此总共有 m^n 种放法。

(b) 无放回抽样：每个物品只能放入一个盒子，因此总共有 $P_m^n = \frac{m!}{(m-n)!}$ 种放法。

(c) 无放回抽样（组合）：每个物品只能放入一个盒子，且不考虑顺序，因此总共有 $C_m^n = \frac{m!}{n!(m-n)!}$ 种放法。

定义 II.1.9: 几何概型

几何概型是指在几何空间中，事件的概率通过测度来定义。通常用于处理连续样本空间中的事件。

公式 .6: 几何概型的计算方法

在几何空间中，概率可以通过测度来定义。设样本空间 Ω 的测度为 $m(\Omega)$ ，事件 A 的测度为 $m(A)$ ，则事件 A 的概率为：

$$P(A) = \frac{m(A)}{m(\Omega)}$$

其中， $m(A)$ 和 $m(\Omega)$ 分别表示事件 A 和样本空间 Ω 的测度。

落到计算上，就是长度、面积或体积的比值。这可以和高数结合起来

1.5 概率论性质与公式

结论 II.1.1: 概率论的性质

1. 有界性

对于任一事件 A , 有 $0 \leq P(A) \leq 1$, 且 $P(\emptyset) = 0, P(\Omega) = 1$ 。

2. 单调性

如果 $A \subset B$, 则 $P(B - A) = P(B) - P(A)$, 且 $P(B) \geq P(A)$ 。

公式 .7: 概率论的公式

1. 加法公式

如果 $A_1, A_2, \dots, A_n$ 是互斥的事件, 则 $P(A_1 \cup A_2 \cup \dots \cup A_n) = P(A_1) + P(A_2) + \dots + P(A_n)$ 。

2. 求逆公式

如果 A 是事件 B 的子集, 则 $P(\bar{A}) = 1 - P(A)$ 。

3. 减法公式

如果 A 是事件 B 的子集, 则 $P(B - A) = P(B) - P(A)$ 。

4. 乘法公式

如果 $A_1, A_2, \dots, A_n$ 是独立的事件, 则 $P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \times P(A_2) \times \dots \times P(A_n)$ 。

5. 条件概率公式

如果 A 是事件 B 的子集, 则 $P(A|B) = \frac{P(A \cap B)}{P(B)}$ 。

6. 全概率公式

如果 $A_1, A_2, \dots, A_n$ 是互斥的事件, 则 $P(A) = P(A_1) + P(A_2) + \dots + P(A_n)$ 。

7. 贝叶斯公式

如果 $A_1, A_2, \dots, A_n$ 是互斥的事件, 则

$$P(B_k|A) = \frac{P(B_k)P(A|B_k)}{P(A)}$$

8. n 重伯努利试验

$$P_n(A = k) = C_n^k p^k (1 - p)^{n-k}$$

1.6 事件的独立性

定义 II.1.10: 事件的独立性

如果 A 和 B 是事件, 且 $P(A \cap B) = P(A)P(B)$, 则称 A 和 B 是独立的。A 与 B 相互独立的含义是 A 与 B 在概率上互不影响。A 事件发生的概率不影响 B 事件发生的概率。

结论 II.1.2: 互不相容

如果 A 和 B 是事件, 且 $A \cap B = \emptyset$, 则称 A 和 B 是互不相容的。A 与 B 互不相容的含义是 A 与 B 在概率上不相关。两件事不会同时发生。

定义 II.1.11: 独立与不相容的联系

$P(A) > 0, P(B) > 0, A$ 与 B 独立 $\Rightarrow A$ 与 B 相容

A 与 B 互不相容, $P(A) > 0, P(B) > 0 \Rightarrow A$ 与 B 不互相独立

结论 II.1.3: 四对事件

若 A 与 $B, \bar{A}$ 与 B, A 与 $\bar{B}, \bar{A}$ 与 $\bar{B}$ 有一对相互独立, 则其他三对相互独立

结论 II.1.4: 事件 A 与 B 相互独立的充要条件

$$A \text{ 与 } B \text{ 独立} \Leftrightarrow \begin{cases} 1. P(AB) = P(A)P(B) \\ 2. P(B|A) = P(B), \quad P(A) > 0 \\ P(A|B) = P(A), \quad P(B) > 0 \\ 3. P(B|A) = P(B|\bar{A}), \quad 0 < P(A) < 1 \\ 4. P(B|A) + P(\bar{B}|\bar{A}) = 1, \quad 0 < P(A) < 1 \end{cases}$$

结论 II.1.5: 事件 A,B,C 相互独立的条件

$$\begin{cases} P(AB) = P(A)P(B) \\ P(AC) = P(A)P(C) \\ P(BC) = P(B)P(C) \\ P(ABC) = P(A)P(B)P(C) \end{cases} \Rightarrow A, B, C \text{相互独立}$$

结论 II.1.6: n 个独立事件的概率

$$P(A_1, A_2, \dots, A_n) = P(A_1)P(A_2) \dots P(A_n)$$

$$P(\cup_{i=1}^n A_i) = 1 - \prod_{i=1}^n [1 - P(A_i)]$$

结论 II.1.7: 独立的性质

若 $A_1, A_2, \dots, A_n$ 独立, 则由 $A_{i1}, A_{i2}, \dots, A_{in}$ 经过运算后所得事件 $\sigma_1(A_{i1}, A_{i2}, \dots, A_{in})$ 与 $A_{ik+1}, A_{ik+2}, \dots, A_{in}$ 经过运算后所得事件 $\sigma_2(A_{ik+1}, A_{ik+2}, \dots, A_{in})$ 也独立, $i1, i2, \dots, in$ 为 $1, 2, \dots, n$ 的任何一个排列。

即原本独立的事件, 各自经过运算后所得事件也独立

2 一维随机变量及其分布

2.1 随机变量与分布函数的概念

定义 II.2.1: 随机变量

随机变量是随机试验的结果, 是一个随机试验的函数。设随机试验 E 的样本空间为 Ω , $\omega \in R$ 若对任意实数 x , 事件 $\{X \leq x\} = \{\omega | X(\omega) \leq x\}$

定义 II.2.2: 分布函数

X 是随机变量, x 是任意实数, $F(X) = P(X \leq x)$ 是随机变量 X 的分布函数。称 X 服从 $F(X)$ 分布或 $X \sim F(X)$

结论 II.2.1: 分布函数的性质

1. 分布函数是单调不减函数。
2. $0 \leq F(X) \leq 1$ 。 $F(-\infty) = 0, F(\infty) = 1$ 。
3. $F(X)$ 是右连续函数。 $x_0 \in R$ 时, $F(x_0)$ 存在, 且有

$$\lim_{x \rightarrow x_0^+} F(x) = F(x_0 + 0) = F(x_0)$$

4. 对任意 $x_1 < x_2$, $P\{x_1 \leq X \leq x_2\} = F(x_2) - F(x_1)$
5. 对任意 $x_0 \in R$, $P(X = x_0) = F(x_0) - F(x_0 - 0)$
6. 设 $x_1 < x_2$, 且 $F(X)$ 在 x_1, x_2 处连续, $P\{x_1 \leq X \leq x_2\} = F(x_2) - F(x_1)$

2.2 离散型随机变量及连续型随机变量

定义 II.2.3: 离散型随机变量

如果随机变量 X 只可能取有限个或无限个离散的值, 则为离散型随机变量。 X 的概率分布 (或分布律, 分布列) 可表示为

$$P(X = x_i) = p_i, i = 1, 2, \dots, n$$

或表格形式

X	x_1	x_2	x_3	$\dots$	x_n
P	p_1	p_2	p_3	$\dots$	p_n

或

$$X \sim \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}$$

定义 II.2.4: 连续型随机变量

若随机变量 X 的分布函数 $F(X)$, 存在非负可积函数 $f(x)$, 使得

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

则称 X 为连续型随机变量, $f(x)$ 为 X 的概率密度函数。

注 随机变量的取值并不可列, 转换为 $F(X)$ 求得是落入某一区间的概率。 $f(x)$ 是密度值, 而不是概率值

2.3 离散型随机变量及其分布

定义 II.2.5: 离散型随机变量的分布函数

设 X 是离散型随机变量, $x_1, x_2, \dots, x_n$ 是 X 的可能取值, $P(X = x_i)$ 是 X 取 x_i 的概率, $F(X)$ 是 X 的分布函数, 则有

$$F(X) = P(X \leq x) = P(X = x_1) + P(X = x_2) + \dots + P(X = x_n)$$

表 1: 常见离散型随机变量分布

名字	符号	概率分布
0-1 分布	$P(X = 0)$	$P(X = 0) = 1 - P(X = 1)$
二项分布	$B(n, p)$	$P(X = k) = C_n^k p^k (1 - p)^{n-k}$
泊松分布	$P(\lambda)$	$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$
几何分布	$G(p)$	$P(X = k) = p(1 - p)^{k-1}$
超几何分布	$H(M, N, n)$	$P(X = k) = \frac{C_k^n C_{M-k}^{N-n}}{C_M^N}$

2.4 连续型随机变量及其分布

定义 II.2.6: 连续型随机变量的分布函数

设 X 是连续型随机变量, $f(x)$ 是 X 的概率密度函数, $F(X)$ 是 X 的分布函数, 则有

$$F(X) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

表 1: 常见连续型随机变量分布

名字	符号	分布函数	概率密度函数
均 匀 分布	$U(a, b)$	$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$	$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$
指 数 分布	$E(\lambda)$ ($\lambda > 0$)	$F(X) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$	$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$
正 态 分布	$N(\mu, \sigma)$	$\Phi(X)$	$\phi(x) = f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ ($-\infty < x < \infty$)

结论 II.2.2: 标准正态分布

标准正态分布是正态分布的标准化, 即 $N(0, 1)$, 概率密度函数为

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

其分布函数为

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x t e^{-\frac{t^2}{2}} dt$$

$\phi(x)$ 为偶函数, 则 $\Phi(0) = 0.5$, $\Phi(-x) = 1 - \Phi(x)$ 当 $a > 0$ 时,

$$P(a < X < b) = \Phi(b) - \Phi(a)$$

$$P(|x| \leq a) = 2\Phi(a) - 1$$

结论 II.2.3: 正态分布的标准化

设 X 为正态分布, $X \sim N(\mu, \sigma^2)$, $Y = \frac{X-\mu}{\sigma}$, 则 Y 为标准正态分布。

$$P(a < X < b) = P\left(\frac{a-\mu}{\sigma} < Y < \frac{b-\mu}{\sigma}\right) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$$

2.5 一维随机变量函数的分布

定义 II.2.7: 随机变量的函数

设 X 为随机变量, $Y = f(X)$ 为 X 的函数, Y 也为随机变量, Y 的分布函数为 $F(Y)$, 则有

$$F(Y) = P(Y \leq y) = P(f(X) \leq y) = P(X \leq f^{-1}(y))$$

结论 II.2.4: 离散型随机变量函数的分布

设 X 为离散型随机变量, $Y = f(X)$ 为 X 的函数, Y 也为离散型随机变量, 求 X 的分布律的步骤为

1. 求 $Y = g(X)$ 的所有可能的取值 $a_1, a_2, \dots, a_n$
2. 计算 $P(Y = a_i)$, 若 a_i 相同, 合并其概率值

结论 II.2.5: 连续型随机变量函数的分布

设 X 为连续型随机变量, $Y = f(X)$ 为 X 的函数, Y 也为连续型随机变量, 求 X 的分布律有两种方法

1. 定义法 (分布函数法)

设 $Y = f(X)$ 的分布函数为 $F(Y)$, 则有

$$\begin{aligned} F(Y) &= P(Y \leq y) \\ &= P(f(X) \leq y) = P(X \leq f^{-1}(y)) \\ &= \int_{g(x) \leq y} f_X(x) dx \end{aligned}$$

$Y = f(X)$ 的概率密度函数为 $f(y)$ 为

$$f(y) = \frac{dF_Y(y)}{dy}$$

2. 若 $g'(x) \neq 0, y = g(x)$ 与其反函数 $x = h(y)$ 单调性一致。 故

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(g(x) \leq y) = P(X \geq h(y)) \\ f_Y(y) &= F'_Y(y) = f_X(h(y)) |h'(y)| \end{aligned}$$

$$f_Y(y) = \begin{cases} f_X(h(y)) |h'(y)|, & \alpha < y < \beta \\ 0, & \text{其他} \end{cases}$$

其中 α 为 Y 的下限, β 为 Y 的上限。

$$\alpha = \min\left\{\lim_{x \rightarrow a^+} g(x), \lim_{x \rightarrow b^-} g(x)\right\}, \beta = \max\left\{\lim_{x \rightarrow a^-} g(x), \lim_{x \rightarrow b^+} g(x)\right\}$$

2.6 一些其他技巧

结论 II.2.6: 泊松积分

$$\int_{-\infty}^{\infty} e^{-t^2} dt = \sqrt{\pi}$$

结论 II.2.7: 泊松分布下的比例问题

$X \sim P(\lambda)$, 则 $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$

在 X 中发生 Y 的比例为 α ,

Y 的分布为 $P(\alpha\lambda)$, 则 $P(Y = k) = \frac{(\lambda\alpha)^k e^{-\lambda\alpha}}{k!}$

结论 II.2.8: 标准柯西分布

$X \sim \text{Cauchy}(0, 1)$

$F(x) = \frac{1}{\pi} \arctan x$

$f(x) = \frac{1}{\pi(1+x^2)}$ 标准柯西分布即是自由度为 1 的 t 分布, $X \sim t(1)$, 其 EX, DX 均不存在

结论 II.2.9: 几何分布与指数分布的无记忆性

即无论等待了多久, 下一个瞬间事件发生的概率 (或等待时间) 和从头开始等待是完全一样的。过去的等待不会给未来带来任何“积累”或“优势”。

$$P(X > m + n | X > m) = P(X > n)$$

结论 II.2.10: 两个变换

1. $F_X(x)$ 在 X 的正概率密度区间上严格单调递增, 若 $X \sim F_X(x)$, 则 $F_X(x) \sim U(0, 1)$
2. 设随机变量 X 的分布函数 $F_X(x)$ 连续, 且 $F_X(x)$ 在 X 的正概率密度区间上严格单调且 $Y = -\ln[1 - F_X(x)]$, 随机变量 Y 服从指数分布 $E(1)$

3 多维随机变量的函数分布

3.1 二维随机变量联合分布函数与边缘分布函数

定义 II.3.1: 二维随机变量

设 $X = X(\omega)$, $Y = Y(\omega)$ 是定义在样本空间 Ω 上的随机变量, 则称向量 (X, Y) 是二维随机变量。

定义 II.3.2: 二维随机变量的联合分布函数

$$\begin{aligned} F(x, y) &= P((X \leq x) \cap P(Y \leq y)) \\ &= P(X \leq x, Y \leq y) (-\infty \leq x, y \leq +\infty) \end{aligned}$$

为二维随机变量 (X, Y) 的分布函数, 也称为对随机变量 X, Y 的联合分布函数

结论 II.3.1: 二维随机变量的联合分布函数的性质

1. $0 \leq F(x, y) \leq 1$, 且对 x, y 单调不减

2.

$$F(-\infty, y) = \lim_{x \rightarrow -\infty} F(x, y) = 0$$

$$F(x, -\infty) = \lim_{y \rightarrow -\infty} F(x, y) = 0$$

$$F(-\infty, -\infty) = \lim_{x, y \rightarrow -\infty} F(x, y) = 0$$

$$F(+\infty, +\infty) = \lim_{x, y \rightarrow +\infty} F(x, y) = 1$$

3. $F(x, y)$ 关于 x, y 右连续, 即
$$\begin{aligned} F(x+0, y) &= F(x, y) \\ F(x, y+0) &= F(x, y) \end{aligned}$$

4. 区域 $D = \{(x, y) | x_1 < X \leq x_2, y_1 < Y \leq y_2\}$ 上的概率为

$$\begin{aligned} P\{(X, Y) \in D\} &= P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} \\ &= F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1) \end{aligned}$$

定义 II.3.3: 二维随机变量的边缘分布函数

设二维随机变量的分布函数为

$$F(x, y) = P(X \leq x, Y \leq y)$$

其中 X 的分布函数为

$$\begin{aligned} F_X(x) &= P(X \leq x) \\ &= P(X \leq x, Y < +\infty) \\ &= F(x, +\infty) \\ &= \lim_{y \rightarrow +\infty} F(x, y) \end{aligned}$$

其中 Y 的分布函数为

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(X < +\infty, Y \leq y) \\ &= F(+\infty, y) \\ &= \lim_{x \rightarrow +\infty} F(x, y) \end{aligned}$$

称为二维随机变量 (X, Y) 关于 X 和 Y 的边缘分布函数

3.2 二维离散型随机变量

定义 II.3.4: 二维离散型随机变量的联合概率分布

二维随机变量 (X, Y) 可取有限或无穷可列个取值 (x_i, y_i) , 则称 $P(X = x_i, Y = y_i) = p_{ij}$ 为二维随机变量 (X, Y) 的概率分布, 或随机变量 X 和 Y 的联合概率分布

结论 II.3.2: 二维离散型随机变量的联合概率分布的性质

1. 对所有 i, j , $p_{ij} \geq 0$
2. $\sum_{i=1}^{\infty} \sum_{j=1}^{\infty} p_{ij} = 1$

定义 II.3.5: 二维离散型随机变量的边缘概率分布

设二维随机变量的联合概率分布为

$$p_{ij} = P(X = x_i, Y = y_j)$$

则 p_{ij} 关于 i 的和为

$$p_{i,\cdot} = P(X = x_i) = \sum_{j=1}^{\infty} p_{ij}$$

关于 j 的和为

$$p_{\cdot,j} = P(Y = y_j) = \sum_{i=1}^{\infty} p_{ij}$$

分别称为 X 的边缘概率分布和 Y 的边缘概率分布。

定义 II.3.6: 二维离散型随机变量的条件概率分布

设二维随机变量的联合概率分布为

$$p_{ij} = P(X = x_i, Y = y_j)$$

在 $X = x_i$ 的条件下, Y 的概率分布为

$$P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)} = \frac{p_{ij}}{p_{i,\cdot}}$$

在 $Y = y_j$ 的条件下, X 的概率分布为

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{\cdot,j}}$$

结论 II.3.3: 二维离散型随机变量的条件概率分布的独立性

若 $p_{ij} = p_{i,\cdot} p_{\cdot,j} = P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$, 则称 X 和 Y 独立。

3.3 二维连续型随机变量

定义 II.3.7: 二维连续型随机变量的联合概率密度

设二维随机变量分布函数 $F(x, y)$, 如果存在非负的可积函数 $f(x, y)$, 使得

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

则称 $f(x, y)$ 为二维随机变量 (X, Y) 的概率密度, 为随机变量 X 和 Y 的联合概率密度。

结论 II.3.4: 二维连续型随机变量的联合概率密度的性质

1. $f(x, y) \geq 0$
2. $F(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = F(+\infty, +\infty) = 1$
3. (X, Y) 落在平面区域 D 上的概率为

$$P\{(X, Y) \in D\} = \iint_D f(x, y) dx dy$$

可用来计算不等式

$$P\{Y \leq X\} = P\{(X, Y) \in D\} = \iint_D f(x, y) dx dy$$

4. 若 $f(x, y)$ 在 (x, y) 处连续, 则有 $f(x, y) = \frac{\partial F(x, y)}{\partial x} = \frac{\partial^2 F(x, y)}{\partial x \partial y}$

定义 II.3.8: 二维连续型随机变量的边缘概率密度

设二维随机变量 (X, Y) 的联合概率密度为 $f(x, y)$, 由

$$F_X(x) = F(x, +\infty) = \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f(x, y) dy \right] dx$$

推得 X 的边缘概率密度为

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$$

Y 的边缘概率密度为

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

结论 II.3.5: 二维连续型随机变量的条件概率密度

设二维随机变量 (X, Y) 的联合概率密度为 $f(x, y)$, 边缘概率密度 $f_X(x)$ 和 $f_Y(y)$ 连续且恒大于 0, 则称 $\frac{f(x, y)}{f_Y(y)}$ 为在条件 $Y = y$ 下 X 的条件概率密度, 称 $\frac{f(x, y)}{f_X(x)}$ 为在条件 $X = x$ 下 Y 的条件概率密度, 即

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$$

对于 (X, Y) 的条件分布函数, 有

$$F_{X|Y}(x|y) = \int_{-\infty}^x \frac{f(t, y)}{f_Y(y)} dt$$

$$F_{Y|X}(y|x) = \int_{-\infty}^y \frac{f(x, t)}{f_X(x)} dt$$

公式 .8: 密度乘法公式

$$f(x, y) = f_X(x)f_{Y|X}(y|x) \quad (f_X(x) > 0)$$

$$= f_Y(y)f_{X|Y}(x|y) \quad (f_Y(y) > 0)$$

3.4 二维随机变量的独立性

定义 II.3.9: 独立性

设二维随机变量 (X, Y) 的分布函数及边缘分布函数 $F(x, y), F_X(x), F_Y(y)$

若 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$, 则称 X 和 Y 相互独立。
 $F(x, y) = F_X(x)F_Y(y)$

定义 II.3.10: 相互独立的充分必要条件

1. 二维离散型随机变量

$P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$, 即 $p_{ij} = p_i \cdot p_j (i, j = 1, 2, \dots) \Leftrightarrow X$ 和 Y 相互独立。

2. 二维连续型随机变量

$f(x, y) = f_X(x)f_Y(y)$, 其中 (x, y) 为 $f(x, y), f_X(x), f_Y(y)$ 的连续点
 $\Leftrightarrow X$ 和 Y 相互独立。

[注] 两两独立并不等于相互独立, 如对于三个事件 A, B, C , 两两独立仅

$$P(A, B) = P(A)P(B)$$

能保证 $P(A, C) = P(A)P(C)$

$$P(B, C) = P(B)P(C)$$

而相互独立则要求

$$P(A, B, C) = P(A)P(B)P(C)$$

结论 II.3.6: 相互独立的性质

1. 若随机变量 $X_1, X_2, \dots, X_n$ 相互独立, 则其中任意 $k (2 \leq k \leq n)$ 个随机变量也相互独立
2. 若随机变量 $X_1, X_2, \dots, X_n$ 相互独立, 则它们的函数 $g_1(X_1), g_2(X_2), \dots, g_n(X_n)$ 也相互独立也相互独立。
3. 若两个随机变量独立, 则一个关于另一个的条件分布就是其无条件

件分布，即：对于二维离散型随机变量 (X, Y) ，若 X 与 Y 独立，则条件分布等于其边缘分布，对于二维连续型随机变量 (X, Y) ，若 X 与 Y 独立，则条件密度等于其概率密度

$$P(X = x|Y = y) = P(X = x)$$

$$f_{Y|X}(y|x) = f_Y(y)$$

$$P(Y = y|X = x) = P(Y = y)$$

$$f_{X|Y}(x|y) = f_X(x)$$

3.5 一些常见的多维随机变量函数分布

定义 II.3.11: 二维均匀分布的概念

设 G 是平面上的有界区域，其面积为 A ，若二维随机变量 X, Y 具有联合概率密度

$$f(x, y) = \begin{cases} \frac{1}{A}, & (x, y) \in G \\ 0, & (x, y) \notin G \end{cases}$$

其中 c 为常数，则称 X, Y 服从二维均匀分布。

结论 II.3.7: 二维均匀分布的性质

1.

$$P\{(X, Y) \in D\} = \iint_D f(x, y) dx dy = \iint_D \frac{1}{A} dx dy = \frac{1}{A} S_D$$

即在 G 内， (X, Y) 落在子区域 D 的取值仅与 S_D 有关

2. 二维均匀分布的边缘分布，条件分布，数字特征都与区域 D 的形状密切相关圆形区域边缘分布不是均匀分布，矩形区域的边缘分布是均匀分布

定义 II.3.12: 二维正态分布

如果 (X, Y) 的联合概率密度为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{1}{2(1-\rho^2)}[(\frac{x-\mu_1}{\sigma_1})^2 + (\frac{y-\mu_2}{\sigma_2})^2 - 2\rho\frac{x-\mu_1}{\sigma_1}\frac{y-\mu_2}{\sigma_2}]}$$

则称 X, Y 服从二维正态分布。也称 X, Y 是二维正态变量记为 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$

其中 $\mu_1 = E(X), \mu_2 = E(Y), \sigma_1^2 = D(X), \sigma_2^2 = D(Y), \rho = \frac{Cov(X, Y)}{\sigma_1\sigma_2}$

结论 II.3.8: 二维正态分布的性质

若 X, Y 服从二维正态分布, 则

1. $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 逆命题不成立
2. X 与 Y 相互独立的充要条件是 $\rho = 0$, 即若 X 与 Y 独立, 则 X 与 Y 不相关
3. 两个二维正态分布的随机变量 X, Y 的线性组合也服从正态分布
 $aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2 + 2ab\rho\sigma_1\sigma_2)$

3.6 二维随机变量的函数分布的求法

结论 II.3.9: 一般公式

设 X, Y 为随机变量, $g(x, y)$ 为二元函数, 则 $U = g(X, Y)$ 为随机变量 (X, Y) 的函数。

$$F_U(u) = P(g(X, Y) \leq u) = \begin{cases} \sum_{g(x_i, y_i) \leq u} p_{ij} \\ \iint_{g(x, y) \leq u} f(x, y) dx dy \end{cases}$$

当 X, Y 独立时

$$F_U(u) = P(g(X, Y) \leq u) = \begin{cases} \sum_{g(x_i, y_j) \leq u} p_{i.} p_{.j} \\ \iint_{g(x, y) \leq u} f_X(x) f_Y(y) dx dy \end{cases}$$

结论 II.3.10: 二维离散型随机变量函数分布的求法

$U = g(X, Y)$ 是连续型随机变量, 其分布律为 $P(U = g(x_i, y_i)) = P(X = x_i, Y = y_i) = p_{ij}$

$$U \sim \begin{pmatrix} g(x_i, y_j) & i = 1, 2, \dots, n; j = 1, 2, \dots, m \\ p_{ij} & i = 1, 2, \dots, n; j = 1, 2, \dots, m \end{pmatrix}$$

对于不同的 x_i, x_j , 如果取相同的 $g(x, y)$, 则合并同类项

如果 $U = g_1(X, Y), V = g_2(X, Y)$, 求 U, V 的分布律, 有

$$P(U = u, V = v) = \sum_{i=1}^n \sum_{j=1}^m P(X = x_i, Y = y_j)$$

也可以先求 (U, V) 的边缘分布, 再求 (U, V) 的边缘分布, 最后求 (U, V) 的联合分布也可以通过条件分布求 (U, V) 的联合分布

结论 II.3.11: 二维连续型随机变量函数分布的求法

设 X, Y 为二维连续型随机变量, $U = g(X, Y)$ 为随机变量 (X, Y) 的函数。 (X, Y) 的联合密度函数为 $f(x, y)$

1. 若 $U = g(X, Y)$ 为离散型随机变量, 则

$$P(U = u_i) = \iint_D f(x, y) dx dy \quad (i = 1, 2, \dots)$$

其中 $D = \{(x, y) | g(x, y) = u_i\}$

2. 若 $U = g(X, Y)$ 为连续型随机变量, 则先求分布函数 $F_U(u) = P(U \leq u)$, 再求其密度函数 $f_U(u)$

3. 如果 X 为连续型随机变量, Y 为离散型随机变量, 则

$$\begin{aligned} F_U(u) &= P(U \leq u) = P(g(X, Y) \leq u) \\ &= \sum_i P(X = x_i) P(g(X, Y) \leq u | X = x_i) \\ &= \sum_i p_i P(g(X, Y) \leq u | X = x_i) \end{aligned}$$

若 $U = g_1(X, Y), V = g_2(X, Y)$, 求 U, V 的分布律, 有

1.

$$\begin{aligned} F_Z(z) &= P(g_1(X, Y) \leq u, g_2(X, Y) \leq v) \\ &= \iint_{g_1(x, y) \leq u, g_2(x, y) \leq v} f(x, y) dx dy \end{aligned}$$

2. (U, V) 为离散型随机变量

$$\begin{aligned} P(U = u, V = v) &= P(g_1(X, Y) = u_i, g_2(X, Y) = v_j) \\ &= P((X, Y) \in D) = \iint_D f(x, y) dx dy \end{aligned}$$

$D = \{(x, y) | g_1(x, y) = u_i, g_2(x, y) = v_j\}$ 或利用边缘分布与联合分布求 (U, V) 的分布

表 1: 几个简单二维连续型随机变量函数的分布的卷积公式

函数	卷积公式
$Z = X + Y$	$f_Z(z) = f_X * f_Y$ $= \int_{-\infty}^{\infty} f(z - y, y) dy = \int_{-\infty}^{\infty} f(x, z - x) dx$ $= \int_{-\infty}^{\infty} f_X(z - y) f_Y(y) dy$ $= \int_{-\infty}^{\infty} f_Y(z - x) f_X(x) dx$
$Z = X - Y$	$f_Z(z) = f_X * f_Y$ $= \int_{-\infty}^{\infty} f(x, x - z) dx$ $= \int_{-\infty}^{\infty} f(x + z, x) dx$ $= \int_{-\infty}^{\infty} f_X(x + z) f_Y(x) dx \quad (X, Y \text{ 独立})$
$Z = XY$	$f_{XY}(z) = f_X * f_Y$ $= \int_{-\infty}^{\infty} \frac{1}{ x } f(x, \frac{z}{x}) dx$ $= \int_{-\infty}^{\infty} \frac{1}{ y } f(\frac{z}{y}, y) dy$
$Z = \frac{X}{Y}$	$f_Z(z) = f_X * f_Y$ $= \int_{-\infty}^{\infty} y f(yz, y) dy$
$Z = \max(X, Y)$	$F_{\max}(z) = P(\max(X, Y) \leq z)$ $= P(X \leq z, Y \leq z)$ $= F_X(z) \cdot F_Y(z) \quad (X, Y \text{ 相互独立时})$ $f_{\max}(z) = \frac{dF_Z(z)}{dz}$
$Z = \min(X, Y)$	$F_{\min}(z) = P(\min(X, Y) \leq z)$ $= 1 - P(X \geq z, Y \geq z)$ $= 1 - (1 - P(X \leq z))(1 - P(Y \leq z))$ $= 1 - (1 - F_X(z))(1 - F_Y(z))$

结论 II.3.12: 二重换元法

若 $(X, Y) \sim f(x, y)$, 若 $\begin{cases} u = u(x, y) \\ v = v(x, y) \end{cases}$ 具有一阶连续偏导数, 且存在唯一的反函数 $\begin{cases} x = x(u, v) \\ y = y(u, v) \end{cases}$ 又

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix} \neq 0$$

则 (X, Y) 的函数 $\begin{cases} U = u(x, y) \\ V = v(x, y) \end{cases}$ 的联合概率密度为

$$f_{U,V}(u, v) = f[x(u, v), y(u, v)] \cdot |J|$$

U 的概率密度为

$$f_U(u) = \int_{-\infty}^{\infty} f_{U,V}(u, v) dv$$

V 的概率密度为

$$f_V(v) = \int_{-\infty}^{\infty} f_{U,V}(u, v) du$$

结论 II.3.13: 分布的可加性

X 与 Y 相互独立

1. $X \sim B(n, p), Y \sim B(m, p), X + Y \sim B(n + m, p)$
2. $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2), X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
3. $X \sim P(\lambda_1), Y \sim P(\lambda_2), X + Y \sim P(\lambda_1 + \lambda_2)$
4. $X \sim \chi^2(n), Y \sim \chi^2(m), X + Y \sim \chi^2(n + m)$

上述结论对 n 个变量也成立

3.7 一些其他技巧

定义 II.3.13: $\min$ 与 $\max$ 的经典形式

$$\begin{aligned}\max(X, Y) &= \frac{1}{2}(X + Y + |X - Y|) \\ \min(X, Y) &= \frac{1}{2}(X + Y - |X - Y|)\end{aligned}$$

4 随机变量的数字特征

4.1 随机变量的期望与方差

定义 II.4.1: 随机变量的数学期望

1. 离散型随机变量

设随机变量 X 的概率分布为

$$P(X = x_i) = p_i, i = 1, 2, \dots, n$$

则 X 的数学期望为

$$E(X) = \sum_{i=1}^n x_i p_i$$

其中无穷级数 $\sum_{i=1}^n x_i p_i$ 绝对收敛

2. 连续型随机变量

设随机变量 X 的概率密度函数为 $f(x)$, 则 X 的数学期望为

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

其中积分 $\int_{-\infty}^{+\infty} x f(x) dx$ 绝对收敛

$E(X)$ 是一个实数且完全由 X 的概率分布来确定

结论 II.4.1: 随机变量的数学期望的性质

1. C 为常数, $E(C) = C$
2. C 为常数, $E(CX) = CE(X)$
3. $E(X \pm Y) = E(X) \pm E(Y)$
4. 若 X, Y 相互独立, $E(XY) = E(X)E(Y)$

定义 II.4.2: 随机变量函数的数学期望

1. $Y = g(X)$ 为随机变量 X 的函数

设 X 是离散型随机变量, $g(x)$ 是一个连续函数, 则 $Y = g(X)$ 的数学期望为

$$E(Y) = E(g(X)) = \sum_{i=1}^n g(x_i) p_i$$

设 X 为连续型随机变量, $f(x)$ 为随机变量 X 的概率密度函数, $Y = g(X)$ 的数学期望为

$$E(Y) = E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) dx$$

其中积分 $\int_{-\infty}^{+\infty} g(x) f(x) dx$ 绝对收敛

2. $Z = g(X, Y)$ 为 (X, Y) 的随机变量函数

(X, Y) 为二维离散型随机变量, $g(x, y)$ 是一个连续函数, 则 $Z = g(X, Y)$ 的数学期望为

$$E(Z) = E(g(X, Y)) = \sum_{i=1}^n \sum_{j=1}^m g(x_i, y_j) p_{i,j}$$

其中无穷级数 $\sum_{j=1}^m g(x_i, y_j) p_{i,j}$ 收敛

(X, Y) 为二维连续型随机变量, $g(x, y)$ 是一个连续函数, 则 $Z = g(X, Y)$ 的数学期望为

$$E(Z) = E(g(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

其中积分 $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$ 绝对收敛

定义 II.4.3: 方差与标准差

1. 方差

设随机变量 X 的数学期望为 $E(X)$, 则 X 的方差为

$$D(X) = E[(X - E[X])^2] = E(X^2) - E(X)^2$$

2. 标准差

方差的算术平方根为标准差或均方差

$$\sigma(X) = \sqrt{D(X)}$$

记作 $\sigma(X)$

称 $X^* = \frac{X - E[X]}{\sigma(X)}$ 为随机变量 X 的标准化随机变量
 $E(X^*) = 0, D(X^*) = 1$

公式 .9: 方差公式

$$D(X) = E[(X - E[X])^2] = E(X^2) - E(X)^2$$

结论 II.4.2: 方差性质

1. C 为常数, $D(C) = 0, D(X) = 0$ 的充分必要条件是 X 以概率 1 取常数 C , 即 $P(X = C) = 1, C = E(X)$
2. C 为常数, $D(CX) = C^2 D(X)$
3. C 为常数, $D(X + C) = D(X)$
4. $D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y)$
若 X, Y 相互独立, $D(X \pm Y) = D(X) + D(Y)$

表 1: 常见随机变量的数学期望与方差				
分布	符号	期望	方差	标准差
0 – 1 分布	$X \sim (0, 1)$	p	$p(1 - p)$	$\sqrt{p(1 - p)}$
二项分布	$X \sim B(n, p)$	np	$np(1 - p)$	$\sqrt{np(1 - p)}$
泊松分布	$X \sim P(\lambda)$	λ	λ	$\sqrt{\lambda}$
几何分布	$X \sim G(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	$\sqrt{\frac{1-p}{p^2}}$
均匀分布	$X \sim U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{b-a}{\sqrt{12}}$
指数分布	$X \sim E(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\frac{1}{\lambda}$
正态分布	$X \sim N(\mu, \sigma^2)$	μ	σ^2	σ

4.2 协方差与相关系数

定义 II.4.4: 协方差

设 X, Y 是二维随机变量，如果 $E[E(X - E(X))(Y - E(Y))]$ 存在，则称它为随机变量 X 与 Y 的协方差, 记作

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E(XY) - E(X)E(Y)$$

公式 .10: 协方差公式

1.

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E(XY) - E(X)E(Y)$$

2.

$$D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y)$$

结论 II.4.3: 协方差的性质

1. $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
 2. $\text{Cov}(X, X) = D(X)$
 3. $\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$

4. $\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$
5. $\text{Cov}(X, Y) = 0$ 的充分必要条件是 X 与 Y 相互独立

定义 II.4.5: 相关系数

如果 X, Y 的方差都存在且不为零, 则

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)D(Y)}}$$

为随机变量 X 与 Y 的相关系数.

结论 II.4.4: 相关系数的性质

1. $|\rho(X, Y)| \leq 1$
2. $\rho(X, Y) = 1$ 的充分必要条件是存在常数 a, b , 使得 $P(Y = aX + b) = 1$

结论 II.4.5: X 与 Y 不相关的结论

若 $\rho(X, Y) = 0$ (即 $\text{Cov}(X, Y) = 0$), 则 X 与 Y 不相关.

1. 若随机变量 X 与 Y 独立, 则 X 与 Y 一定不相关, 若 X 与 Y 不相关, 则 X 与 Y 不一定独立
2. 若 (X, Y) 服从二维正态分布, 则 X 与 Y 独立的充要条件是 X 与 Y 不相关
3. 若 X 与 Y 服从 $0-1$ 分布, 则 X 与 Y 独立的充要条件是 X 与 Y 不相关

X 与 Y 不相关

$$\iff \text{Cov}(X, Y) = 0$$

$$\iff E(XY) = E(X)E(Y)$$

$$\iff D(X + Y) = D(X) + D(Y)$$

4.3 随机变量的矩

定义 II.4.6: 随机变量的矩

设 (X, Y) 是二维随机变量, 如果 $E(X^k Y^l)$ 存在, 则称 $E(X^k)$ 为 X 的 k 阶原点矩, 称 $E(X - EX)^k$ 为 X 的 k 阶中心矩. 称 $E(X^k Y^l)$ 为 X 的 k 阶 l 阶混合原点矩. 称 $E[(X - EX)^k (Y - EY)^l]$ 为 X 与 Y 的 $k + l$ 阶混合中心矩

定义 II.4.7: 矩母函数

随机变量 X 的矩母函数 $M(t)$ 定义为

$$M(t) = E[et^X] = \begin{cases} \int_{-\infty}^{\infty} et^x f(x) dx \\ \sum_x e^{tx} p(x) \end{cases}$$

矩可以通过其导数得到. 例如,

$$E(X^k) = M'(t)^k$$

表 1: 矩母函数

原分布	矩母函数
0-1 分布	$M_X(t) = 1 - p + pe^t$
二项分布	$M_X(t) = (1 - p + pe^t)^n$
几何分布	$M_X(t) = \frac{pe^t}{1-(1-p)e^t}$
泊松分布	$M_X(t) = e^{\lambda(e^t-1)}$
均匀分布	$M_X(t) = \frac{1}{b-a} \cdot \frac{e^{tb}-e^{ta}}{t}$
指数分布	$M_X(t) = \frac{\lambda}{\lambda-t}, (t < \lambda)$
正态分布	$M_X(t) = e^{\frac{\sigma^2 t^2}{2} + \mu t}$

4.4 条件期望

公式 .11: 条件期望的定义

$$E(X|Y = y) = \sum_i x_i P(X = x_i|Y = y) = \int_{-\infty}^{\infty} x f(x|y) dx$$
$$E(Y|X = x) = \sum_i y_i P(Y = y_i|X = x) = \int_{-\infty}^{\infty} y f(y|x) dy$$

公式 .12: 重期望公式

$$E(X) = E(E(X|Y))$$

结论 II.4.6: 条件期望的一些性质

1. $D(X) = E(D(X|Y)) + D(E(X|Y))$
2. $E[f(Y)|Y] = f(Y)$
3. $E[g(X)Y|X] = g(X)E[Y|X]$
4. $E(XY) = E[X \cdot E(Y|X)]$
5. $Cov[X, E(Y|X)] = Cov(X, Y)$

4.5 一些技巧

结论 II.4.7: 对形如 $f(x) = Ae^{-(ax^2+bx+c)}$ 的处理

尝试着向正态分布靠拢

即 $A = \frac{1}{\sqrt{2\pi}\sigma}$

$$-(ax^2 + bx + c) = -\frac{(x-\mu)^2}{2\sigma^2}$$

$$-(ax^2 + bx + c) \text{ 可以配方为 } \frac{1}{2\sigma^2}(x - \mu)^2 + k$$

即得

$$\sigma^2 = \frac{1}{2a}, \mu = -\frac{b}{2a}, k = \frac{b^2}{4a} - c$$

5 大数定律与中心极限定理

5.1 大数定律

定义 II.5.1: 依概率收敛

设 $Y_1, Y_2, \dots$ 是随机变量序列, 若 $\lim_{n \rightarrow \infty} P\{|Y_n - a| \leq \varepsilon\} = 1$, 则称 $Y_1, Y_2, \dots$ 依概率收敛于 a , 记作 $Y_n \xrightarrow{p} a$ 。

若 $X_n \xrightarrow{p} a$, $Y_n \xrightarrow{p} b$, 且函数在点 (a, b) 连续, 则 $g(X_n, Y_n) \xrightarrow{p} g(a, b)$

定义 II.5.2: 切比雪夫不等式

设随机变量 X 的数学期望为 $E(X)$, 则对任意 $\varepsilon > 0$, 有

$$P\{|X - E(X)| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2}$$
$$P\{|X - E(X)| \leq \varepsilon\} \geq 1 - \frac{D(X)}{\varepsilon^2}$$

定义 II.5.3: 切比雪夫大数定律

若随机变量

1. 独立
2. $E(X)$ 和 $D(X)$ 都存在, 且 $D(X_i) \leq c$

则有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right) = 1$$

定义 II.5.4: 伯努利大数定律

若随机变量 X_n 服从参数为 n 和 p 的二项分布, 即 $X_n \sim B(n, p)$, μ_n 是 n 次试验中事件 A 发生的次数, 则对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{\mu_n}{n} - p\right| < \varepsilon\right) = 1$$

定义 II.5.5: 辛钦大数定律

若随机变量

1. 独立
2. 期望存在, μ 为共同的期望

则对任意 $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right) = 1$$

结论 II.5.1: 大数定律的实质

大数定律实质即 $\overline{X}_n$ 依概率收敛于 $E(\overline{X}_n)$ 即

$$\overline{X}_n \xrightarrow{P} E(\overline{X}_n)$$

5.2 中心极限定理

定义 II.5.6: 列维林德伯格定理

若随机变量

1. 独立
2. 期望存在, μ 为共同的期望
3. 方差存在, σ^2 为共同的方差

则对任意实数 x , 有

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{\sigma\sqrt{n}}\left(\sum_{i=1}^n X_i - n\mu\right) \leq x\right) = \Phi(x)$$

即 n 很大时, 近似服从正态分布 $N(n\mu, \mu\sigma^2)$

定义 II.5.7: 棣莫夫拉普拉斯定理

设随机变量 Y_n 服从参数为 n, p 的二项分布, 即 $Y_n \sim B(n, p)$, 则对任意实数 x , 有

$$\lim_{n \rightarrow \infty} P\left(\frac{Y_n - np}{\sqrt{np(1-p)}} \leq x\right) = \Phi(x)$$

即 n 很大时, 近似服从正态分布 $N(np, np(1-p))$

结论 II.5.2: 中心极限定理的实质

大数定律研究的是值的收敛, 中心极限定理研究的是分布的收敛, 即 n 很大时, Y_n 的分布近似服从正态分布. 因此我们可以对 Y_n 进行标准化, 即

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x)$$

5.3 其他事项

结论 II.5.3: 大数定律与中心极限定理的一些说明

大数定律与中心极限定理都只是一个猜测, 如果题目中有更准确的方法能计算出值, 则使用更准确的方法.

以上的大数定律可以说条件由弱到强, 条件越来越严格

6 数理统计概念

6.1 统计量及其数字特征

定义 II.6.1: 总体与样本

总体是指待研究的对象的集合，样本是指从总体中抽取的部分对象。设总体为 X ，与 X 同分布的随机变量 $X_1, X_2, \dots, X_n$ 称为样本。 n 为样本容量。 $x_1, x_2, \dots, x_n$ 分别是 $X_1, X_2, \dots, X_n$ 的观测值，则称 $x_1, x_2, \dots, x_n$ 为样本观测值。

结论 II.6.1: 样本的概率分布

1. 分布函数

总体 X 分布函数为 $F(x)$ ，则样本分布函数为

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

2. 概率密度函数

总体 X 概率密度函数为 $f(x)$ ，则样本概率密度函数为

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

3. 联合概率分布

总体 X 联合概率分布为 $P(X = x_i) = p(x_i)$ ，则样本联合概率分布为

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$

定义 II.6.2: 统计量

设 $X_1, X_2, \dots, X_n$ 为样本， $g(X_1, X_2, \dots, X_n)$ 是 $X_1, X_2, \dots, X_n$ 的函数，则称 $g(X_1, X_2, \dots, X_n)$ 为统计量。其中 g 不含任何未知参数

结论 II.6.2: 常用统计量

1. 样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

2. 样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

3. 样本标准差

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

4. 样本 k 阶原点矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

5. 样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

6. 顺序统计量, 即

样本最大值 $\max(X_1, X_2, \dots, X_n)$

样本最小值 $\min(X_1, X_2, \dots, X_n)$

无论什么分布, 期望与方差均存在, 则总有

$$E(\bar{X}) = E(X) = \mu, D(\bar{X}) = \frac{D(X)}{n} = \frac{\sigma^2}{n}$$
$$E(S^2) = D(S) = \sigma^2,$$

6.2 抽样分布

定义 II.6.3: χ^2 分布

设 $X_1, X_2, \dots, X_n$ 为独立随机变量, 且均服从标准正态分布, 则 χ^2 分布为

$$\chi^2 = \sum_{i=1}^n X_i^2$$

$\chi^2(n)$ 中的 n 为自由度对于给定的 α , 称满足

$$P(\chi^2 > \chi_\alpha^2(n)) = \alpha$$

其中 χ_α^2 为 χ^2 分布的上 α 分位数.

结论 II.6.3: χ^2 分布的性质

1. $E(\chi^2) = n, D(\chi^2) = 2n$.
2. 可加性, $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$, 若 χ_1^2, χ_2^2 相互独立, 则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$

定义 II.6.4: t 分布

设 $X \sim N(0, 1), Y \sim \chi^2(n)$, 则 $t = \frac{X}{\sqrt{Y/n}}$ 服从 t 分布. 记作 $t(n)$, t 分布密度函数关于 $X = 0$ 对称, 对于给定的 α , 称满足

$$P(t > t_\alpha(n)) = \alpha$$

其中 $t_\alpha(n)$ 为 $t(n)$ 分布的上 α 分位数. 因为 t 分布密度函数对称, 所以 $t_{1-\alpha}(n) = -t_\alpha(n)$

结论 II.6.4: t 分布的性质

1. $E(t) = 0$,
2. $\lim_{n \rightarrow \infty} f(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$
3. $t \sim t(n), t^2 \sim F(1, n)$

定义 II.6.5: F 分布

设 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, 则 $F = \frac{X/n_1}{Y/n_2}$ 服从 F 分布. 记作 $F(n_1, n_2)$, 其中 n_1, n_2 为自由度.

对于给定的 α , 称满足

$$P(F > F_\alpha(n_1, n_2)) = \alpha$$

其中 $F_\alpha(n_1, n_2)$ 为 $F(n_1, n_2)$ 分布的上 α 分位数.

结论 II.6.5: F 分布的性质

1. $F \sim F(n_1, n_2), \frac{1}{F} \sim F(n_2, n_1)$

2. $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$

6.3 正态总体的样本均值与方差的分布

结论 II.6.6: 单个正态总体

1. $\bar{X}$, 样本均值

$$\begin{aligned}\bar{X} &\sim N\left(\mu, \frac{\sigma^2}{n}\right) \\ \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} &= \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1) \\ \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} &= \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1)\end{aligned}$$

2. $\frac{S^2}{\sigma^2}$, 样本方差

$$\begin{aligned}\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 &\sim \chi^2(n) \\ \frac{(n-1)S^2}{\sigma^2} &\sim \chi^2(n-1)\end{aligned}$$

结论 II.6.7: 两个正态总体

$$\begin{aligned}\bar{X} &= \frac{\sum_{i=1}^{n_1} X_i}{n_1}, \quad \bar{Y} = \frac{\sum_{i=1}^{n_2} Y_i}{n_2} \\ S_X^2 &= \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2}{n_1 - 1}, \quad S_Y^2 = \frac{\sum_{i=1}^{n_2} (Y_i - \bar{Y})^2}{n_2 - 1} \\ S_{XY}^2 &= \frac{(n_1 - 1)S_X^2 + (n_2 - 1)S_Y^2}{n_1 + n_2 - 2}\end{aligned}$$

1. 样本均值差

$$\begin{aligned}\bar{X} - \bar{Y} &\sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}) \\ \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} &\sim N(0, 1) \\ \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_{XY} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} &\sim t(n_1 + n_2 - 2) \quad (\sigma_1^2 = \sigma_2^2)\end{aligned}$$

2. 样本方差比

$$\begin{aligned}F &= \frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1) \\ \frac{(n_1 + n_2 - 2)S_{XY}^2}{\sigma^2} &\sim \chi^2(n_1 + n_2 - 2)\end{aligned}$$

结论 II.6.8: $X(n) = \max(X_1, X_2, \dots, X_n)$

与 $X(n) = \min(X_1, X_2, \dots, X_n)$

$$F_{\max}(x) = P(\max(X_1, X_2, \dots, X_n) \leq x) = [F(X)]^n$$

$$F_{\min}(x) = P(\min(X_1, X_2, \dots, X_n) \geq x) = 1 - [1 - F(X)]^n$$

7 参数统计与假设检验

7.1 参数统计

定义 II.7.1: 估计量, 估计值与点估计

从总体 X 中抽取样本 $X_1, X_2, \dots, X_n$, 相应的样本值 $x_1, x_2, \dots, x_n$, 构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 则 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 X 的一个估计量, 相应的 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 X 的一个估计值, 而 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 是 X 的一个点估计.

定义 II.7.2: 矩估计

设 θ 是 X 的一个未知参数, 若 $\hat{\theta}$ 是 X 的一个矩估计, 则 $\hat{\theta}$ 称为 X 的一个矩估计量.

1. 计算总体 X 的前 k 阶原点矩
2. 计算样本 $X_1, X_2, \dots, X_n$ 的前 k 阶原点矩, 令样本矩 = 总体矩, 即得

$$\frac{1}{n} \sum_{i=1}^n X_i^k = E(X^k)$$

3. 求解上述方程, 即可得 $\hat{\theta}$ 的矩估计量.

定义 II.7.3: 最大似然估计

设 $X_1, X_2, \dots, X_n$ 是 X 的一个样本, 则 $X_1, X_2, \dots, X_n$ 的最大似然估计量为

$$\hat{\theta} = \arg \max_{\theta} L(\theta) = \arg \max_{\theta} \prod_{i=1}^n f(x_i; \theta)$$

其中 $L(\theta)$ 称为 $X_1, X_2, \dots, X_n$ 的最大似然函数. 求解步骤为

1. 写出 $L(\theta)$ 的函数表达式.
2. 对 $L(\theta)$ 或 $\ln L(\theta)$ 求导, 并令导数等于零, 即可得 $\hat{\theta}$ 的最大似然估计量. 若求导无解, 则利用单调性来求解.

结论 II.7.1: 最大似然估计的性质

最大似然估计具有不变性, 即若 $u(\theta)$ 是 θ 的一个函数, 则 $\hat{\theta}$ 也是 $u(\hat{\theta})$ 的最大似然估计

例

$$\hat{\sigma}^2 = \frac{1}{n} \sum_i^n (X_i - \bar{X})^2$$

可得

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_i^n (X_i - \bar{X})^2}$$

结论 II.7.2: 估计量的评选标准

1. 无偏性, 即 $E(\hat{\theta}) = E(\theta)$
2. 有效性, 即若 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效.
3. 一致性, 即当 $n \rightarrow \infty$ 时, $\hat{\theta}_n$ 依概率收敛于 θ , 则称 $\hat{\theta}_n$ 是 θ 的一个一致估计量.

定义 II.7.4: 区间估计

区间估计就是用区间来刻画未知参数所在的范围, 即 $P(\theta \in I) = 1 - \alpha$, 其中 I 是一个区间, α 是一个给定的显著性水平.

1. 单侧置信区间

对于给定值 α , 单侧置信区间为

$$P(\theta \leq \hat{\theta}) = 1 - \alpha$$

2. 双侧置信区间

对于给定值 α , 双侧置信区间为

$$P(\theta \in I) = 1 - \alpha$$

即

$$P(\theta_1 < \theta < \theta_2) = 1 - \alpha$$

结论 II.7.3: 对区间估计的一些理解

正态总体均值或方差总体还是依据估计及分布来求, 或许可以才这方面入手来推出均值差, 方差比的置信区间.

表 1: 常见置信区间

条件	置信区间
σ^2 已知, 求 μ	$(\bar{X} - \frac{\sigma}{\sqrt{n}}z_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma}{\sqrt{n}}z_{\frac{\alpha}{2}})$
σ^2 未知, 求 μ	$(\bar{X} - t_{\frac{\alpha}{2}}(n-1)\frac{\sqrt{s^2}}{\sqrt{n}}, \bar{X} + t_{\frac{\alpha}{2}}(n-1)\frac{\sqrt{s^2}}{\sqrt{n}})$
μ 已知, 求 σ^2	$(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\frac{\alpha}{2}}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\frac{\alpha}{2}}^2(n)})$
μ 未知, 求 σ^2	$(\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)})$

7.2 假设检验

定义 II.7.5: 假设检验

假设检验就是根据样本数据来判断总体参数是否等于某个特定值的过程.

定义 II.7.6: 原假设与备择假设

原假设 H_0 是指总体参数满足某个条件的假设, 而备择假设 H_1 是指与 H_0 对立的假设

定义 II.7.7: 显著性水平与显著性检验

显著性水平 α 是指在假设检验中, 拒绝原假设的概率. 若 $P(\text{拒绝 } H_0 | H_0 \text{ 为真}) = \alpha$, 则称 α 是检验的显著性水平.

结论 II.7.4: 假设检验的一般步骤

1. 确定原假设与备择假设
2. 确定显著性水平
3. 计算检验统计量
4. 确定拒绝区域
5. 计算 p 值
6. 做出判断

结论 II.7.5: 对正态总体均值方差检验的理解

或许可以通过正态总体均值方差的分布推出这些检验的统计量的分布.

表 1: 正态总体均值方差的假设检验

条件	假设	拒绝域
σ^2 已知, μ 未知	$H_0 : \mu = \mu_0, H_1 : \mu \neq \mu_0$	$(-\infty, \mu_0 - \frac{\sigma}{\sqrt{n}}z_{\frac{\alpha}{2}}]$ $\cap [\mu_0 + \frac{\sigma}{\sqrt{n}}z_{\frac{\alpha}{2}}, +\infty)$
σ^2 未知, μ 未知	$H_0 : \mu = \mu_0, H_1 : \mu \neq \mu_0$	$(-\infty, \mu_0 - t_{\frac{\alpha}{2}}(n-1)\frac{\sqrt{s^2}}{\sqrt{n}}]$ $\cap [\mu_0 + t_{\frac{\alpha}{2}}(n-1)\frac{\sqrt{s^2}}{\sqrt{n}}, +\infty)$
σ^2 已知, μ 未知	$H_0 : \mu \leq \mu_0, H_1 : \mu > \mu_0$	$[\mu_0 + \frac{\sigma}{\sqrt{n}}z_{\alpha}, +\infty)$
σ^2 已知, μ 未知	$H_0 : \mu \geq \mu_0, H_1 : \mu < \mu_0$	$(-\infty, \mu_0 - \frac{\sigma}{\sqrt{n}}z_{\alpha}]$
σ^2 未知, μ 未知	$H_0 : \mu \leq \mu_0, H_1 : \mu > \mu_0$	$[\mu_0 + t_{\frac{\alpha}{2}}(n-1)\frac{\sqrt{s^2}}{\sqrt{n}}, +\infty)$
σ^2 未知, μ 未知	$H_0 : \mu \geq \mu_0, H_1 : \mu < \mu_0$	$(-\infty, \mu_0 - t_{\frac{\alpha}{2}}(n-1)\frac{\sqrt{s^2}}{\sqrt{n}}]$